

Gibbs-Sampling mit Metropolis-Hastings-Schritt für Threshold-VAR-Modelle und stochastische Volatilitätsmodelle

Tim Baumann

timbaumann.info/gibbs-her

29. April 2016

1 Das Threshold-VAR-Modell

Bayesische Inferenz (mit Random-Walk-MH)

2 Metropolis-Hastings mit unabhängiger Kandidatenverteilung

3 Das stochastische Volatilitätsmodell

Bayesische Inferenz (mit unabhängigem MH)

4 Erweiterte Version des stochastischen Volatilitätsmodells

Bayesische Inferenz (mit unabhängigem MH)

Das Threshold-VAR-Modell

$$(\text{TVAR}) \quad \begin{cases} Y_t = c_1 + \sum_{j=1}^P \beta_1 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_1 & \text{wenn } S_t \leq Y^* \\ Y_t = c_2 + \sum_{j=1}^P \beta_2 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_2 & \text{wenn } S_t > Y^* \end{cases}$$

wobei $S_t := Y_{j,t-d}$ (*Threshold-Variable*)

$$Y_t, v_t, c_1, c_2 \in \mathbb{R}^N, \quad \beta_1, \beta_2 \in \mathbb{R}^{N \times N}, \quad \Omega_1, \Omega_2 \in \mathbb{R}^{N \times N}, \quad Y^* \in \mathbb{R}$$

Dabei wird die Threshold-Komponente j von Y und die Verzögerung d vom Anwender gewählt.

Das Threshold-VAR-Modell

$$(\text{TVAR}) \quad \begin{cases} Y_t = c_1 + \sum_{j=1}^P \beta_1 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_1 & \text{wenn } S_t \leq Y^* \\ Y_t = c_2 + \sum_{j=1}^P \beta_2 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_2 & \text{wenn } S_t > Y^* \end{cases}$$

wobei $S_t := Y_{j,t-d}$ (*Threshold-Variable*)

$$Y_t, v_t, c_1, c_2 \in \mathbb{R}^N, \quad \beta_1, \beta_2 \in \mathbb{R}^{N \times N}, \quad \Omega_1, \Omega_2 \in \mathbb{R}^{N \times N}, \quad Y^* \in \mathbb{R}$$

Dabei wird die Threshold-Komponente j von Y und die Verzögerung d vom Anwender gewählt.

Beispiel

Makroökonomische Modellierung, wobei vermutet wird, dass die Stärke wirtschaftlicher Zusammenhänge (z. B. Multiplikator für Staatsausgaben) in Wirtschaftskrisen unterschiedlich groß ist wie in wirtschaftlich normalen oder guten Zeiten.

Bayessche Inferenz im Threshold-VAR-Modell

$$\text{(TVAR)} \quad \begin{cases} Y_t = \mathbf{c}_1 + \sum_{j=1}^P \beta_1 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_1 & \text{wenn } S_t \leq Y^* \\ Y_t = \mathbf{c}_2 + \sum_{j=1}^P \beta_2 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_2 & \text{wenn } S_t > Y^* \end{cases}$$

wobei $S_t := Y_{j,t-d}$ (*Threshold-Variable*)

Bayessche Inferenz im Threshold-VAR-Modell

$$\text{(TVAR)} \quad \begin{cases} Y_t = c_1 + \sum_{j=1}^P \beta_1 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_1 & \text{wenn } S_t \leq Y^* \\ Y_t = c_2 + \sum_{j=1}^P \beta_2 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_2 & \text{wenn } S_t > Y^* \end{cases}$$

wobei $S_t := Y_{j,t-d}$ (*Threshold-Variable*)

Prior-Verteilung

Bayessche Inferenz im Threshold-VAR-Modell

$$\text{(TVAR)} \quad \begin{cases} Y_t = \mathbf{c}_1 + \sum_{j=1}^P \beta_1 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_1 & \text{wenn } S_t \leq Y^* \\ Y_t = \mathbf{c}_2 + \sum_{j=1}^P \beta_2 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_2 & \text{wenn } S_t > Y^* \end{cases}$$

wobei $S_t := Y_{j,t-d}$ (*Threshold-Variable*)

Prior-Verteilung

- Für den Threshold: $p(Y^*) \sim \mathcal{N}(\bar{Y}^*, \sigma_{Y^*})$

Bayessche Inferenz im Threshold-VAR-Modell

$$\begin{aligned}
 (\text{TVAR}) \quad & \begin{cases} Y_t = \mathbf{c}_1 + \sum_{j=1}^P \beta_1 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_1 & \text{wenn } S_t \leq Y^* \\ Y_t = \mathbf{c}_2 + \sum_{j=1}^P \beta_2 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_2 & \text{wenn } S_t > Y^* \end{cases} \\
 & \text{wobei } S_t := Y_{j,t-d} \text{ (Threshold-Variable)}
 \end{aligned}$$

Prior-Verteilung

- Für den Threshold: $p(Y^*) \sim \mathcal{N}(\bar{Y}^*, \sigma_{Y^*})$
- Für die VAR-Parameter $\mathbf{b}_1, \mathbf{b}_2 \in \mathbb{R}^{(1+NP) \cdot N}$ und $\Omega_1, \Omega_2 \in \mathbb{R}^{N \times N}$ verwenden wir die Normal-Inverse-Wishart-Verteilung mit Dummy-Observations $X_{D,i} \in \mathbb{R}^{k_i \times (1+NP)}$, $Y_{D,i} \in \mathbb{R}^{k_i \times N}$ ($i = 1, 2$):

$$\begin{aligned}
 p(\mathbf{b}_i | \Omega_i) &\sim \mathcal{N}(\text{vec}(B_{D,i}), \Omega_i \otimes (X_{D,i}^T X_{D,i})^{-1}), \\
 p(\Omega_i) &\sim \mathcal{IW}(S_{D,i}, \text{TODO : } T_{D,i} - ???)
 \end{aligned}$$

$$\begin{aligned}
 \text{wobei} \quad B_{D,i} &:= (X_{D,i}^T X_{D,i})^{-1} (X_{D,i} Y_{D,i}) \in \mathbb{R}^{(1+NP) \times N} \\
 S_{D,i} &:= (Y_{D,i} - X_{D,i} B_{D,i})^T (Y_{D,i} - X_{D,i} B_{D,i}) \in \mathbb{R}^{N \times N}
 \end{aligned}$$

Bayessche Inferenz im Threshold-VAR-Modell

Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold γ^*
(z. B. den Durchschnitt oder den Median der Werte S_t)

Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Treshold Y^*
(z. B. den Durschnitt oder den Median der Werte S_t)
- B. Gibbs-Sampling: Wiederhole die Schritte

Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold Y^*
(z. B. den Durchschnitt oder den Median der Werte S_t)
- B. Gibbs-Sampling: Wiederhole die Schritte
 1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :

Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold Y^*
(z. B. den Durchschnitt oder den Median der Werte S_t)
- B. Gibbs-Sampling: Wiederhole die Schritte
 1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :
 - Beobachtung: Ist Y^* bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime $S_t \leq Y^*$, eines für $S_t > Y^*$.

Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold Y^*
(z. B. den Durchschnitt oder den Median der Werte S_t)
- B. Gibbs-Sampling: Wiederhole die Schritte
1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :
 - Beobachtung: Ist Y^* bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime $S_t \leq Y^*$, eines für $S_t > Y^*$.
 - Seien $Y_{1,t}$, $X_{1,t}$ die zum Regime $S_t \leq Y^*$ und $Y_{2,t}$, $X_{2,t}$ die zum Regime $S_t > Y^*$ zugehörigen Daten.

Bayessche Inferenz im Threshold-VAR-Modell

A. Initialisierung: Wähle einen Startwert für den Threshold Y^*

(z. B. den Durchschnitt oder den Median der Werte S_t)

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :

- Beobachtung: Ist Y^* bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime $S_t \leq Y^*$, eines für $S_t > Y^*$.
- Seien $Y_{1,t}$, $X_{1,t}$ die zum Regime $S_t \leq Y^*$ und $Y_{2,t}$, $X_{2,t}$ die zum Regime $S_t > Y^*$ zugehörigen Daten.
- Ziehe b_1 , b_2 , Ω_1 , Ω_2 aus der Posterior-Verteilung

$$\begin{aligned} p(b_i | \Omega_i, Y_{i,t}) &\sim \mathcal{N}(\text{vec}(B_i^*), \Omega_i \otimes ((X_i^*)^T X_i^*)^{-1}), \\ p(\Omega_i, Y_{i,t}) &\sim \mathcal{IW}(S_i^*, \text{TODO : } T_i^* - ???) \end{aligned}$$

$$\begin{aligned} \text{wobei } B_i^* &:= ((X_i^*)^T X_i^*)^{-1} (X_i^{*T} Y_i^*) \\ S_i^* &:= (Y_i^* - X_i^{*T} B_i^*)^T (Y_i^* - X_i^{*T} B_i^*) \\ Y_i^* &:= [Y_{i,t}, Y_{D,i}] \\ X_i^* &:= [X_{i,t}, X_{D,i}] \end{aligned}$$

Bayessche Inferenz im Threshold-VAR-Modell

A. Initialisierung: Wähle einen Startwert für den Threshold Y^*

(z. B. den Durchschnitt oder den Median der Werte S_t)

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :

- Beobachtung: Ist Y^* bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime $S_t \leq Y^*$, eines für $S_t > Y^*$.
- Seien $Y_{1,t}, X_{1,t}$ die zum Regime $S_t \leq Y^*$ und $Y_{2,t}, X_{2,t}$ die zum Regime $S_t > Y^*$ zugehörigen Daten.
- Ziehe $b_1, b_2, \Omega_1, \Omega_2$ aus der Posterior-Verteilung

$$\begin{aligned} p(b_i | \Omega_i, Y_{i,t}) &\sim \mathcal{N}(\text{vec}(B_i^*), \Omega_i \otimes ((X_i^*)^T X_i^*)^{-1}), \\ p(\Omega_i, Y_{i,t}) &\sim \mathcal{IW}(S_i^*, \text{TODO : } T_i^* - ???) \end{aligned}$$

$$\begin{aligned} \text{wobei } B_i^* &:= ((X_i^*)^T X_i^*)^{-1} (X_i^{*T} Y_i^*) \\ S_i^* &:= (Y_i^* - X_i^{*T} B_i^*)^T (Y_i^* - X_i^{*T} B_i^*) \\ Y_i^* &:= [Y_{i,t}, Y_{D,i}] \\ X_i^* &:= [X_{i,t}, X_{D,i}] \end{aligned}$$

2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für Y^* aus:

Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold Y^*
(z. B. den Durchschnitt oder den Median der Werte S_t)
- B. Gibbs-Sampling: Wiederhole die Schritte
1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :
 - Beobachtung: Ist Y^* bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime $S_t \leq Y^*$, eines für $S_t > Y^*$.
 - Seien $Y_{1,t}, X_{1,t}$ die zum Regime $S_t \leq Y^*$ und $Y_{2,t}, X_{2,t}$ die zum Regime $S_t > Y^*$ zugehörigen Daten.
 - Ziehe $b_1, b_2, \Omega_1, \Omega_2$ aus der Posterior-Verteilung $p(b_i | \Omega_i, Y_{i,t})$, $p(\Omega_i, Y_{i,t})$.
 2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für Y^* aus:

Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold Y^*
(z. B. den Durchschnitt oder den Median der Werte S_t)
- B. Gibbs-Sampling: Wiederhole die Schritte
1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :
 - Beobachtung: Ist Y^* bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime $S_t \leq Y^*$, eines für $S_t > Y^*$.
 - Seien $Y_{1,t}$, $X_{1,t}$ die zum Regime $S_t \leq Y^*$ und $Y_{2,t}$, $X_{2,t}$ die zum Regime $S_t > Y^*$ zugehörigen Daten.
 - Ziehe $b_1, b_2, \Omega_1, \Omega_2$ aus der Posterior-Verteilung $p(b_i | \Omega_i, Y_{i,t})$, $p(\Omega_i, Y_{i,t})$.
 2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für Y^* aus:
 - Generiere einen Kandidaten Y_{new}^* durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold Y^*
(z. B. den Durchschnitt oder den Median der Werte S_t)
- B. Gibbs-Sampling: Wiederhole die Schritte
1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :
 - Beobachtung: Ist Y^* bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime $S_t \leq Y^*$, eines für $S_t > Y^*$.
 - Seien $Y_{1,t}$, $X_{1,t}$ die zum Regime $S_t \leq Y^*$ und $Y_{2,t}$, $X_{2,t}$ die zum Regime $S_t > Y^*$ zugehörigen Daten.
 - Ziehe $b_1, b_2, \Omega_1, \Omega_2$ aus der Posterior-Verteilung $p(b_i | \Omega_i, Y_{i,t})$, $p(\Omega_i, Y_{i,t})$.
 2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für Y^* aus:
 - Generiere einen Kandidaten Y_{new}^* durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit $\alpha = \min(1, r)$ mit

$$r = \frac{\pi(\phi^{G+1})}{\pi(\phi^G)} \cdot \frac{q(\phi^G | \phi^{G+1})}{q(\phi^{G+1} | \phi^G)}$$

Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold Y^*
(z. B. den Durchschnitt oder den Median der Werte S_t)
- B. Gibbs-Sampling: Wiederhole die Schritte
1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :
 - Beobachtung: Ist Y^* bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime $S_t \leq Y^*$, eines für $S_t > Y^*$.
 - Seien $Y_{1,t}, X_{1,t}$ die zum Regime $S_t \leq Y^*$ und $Y_{2,t}, X_{2,t}$ die zum Regime $S_t > Y^*$ zugehörigen Daten.
 - Ziehe $b_1, b_2, \Omega_1, \Omega_2$ aus der Posterior-Verteilung $p(b_i | \Omega_i, Y_{i,t}), p(\Omega_i, Y_{i,t})$.
 2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für Y^* aus:
 - Generiere einen Kandidaten Y_{new}^* durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit $\alpha = \min(1, r)$ mit

$$r = \frac{\pi(\phi^{G+1})}{\pi(\phi^G)} \cdot \frac{q(\phi^G | \phi^{G+1})}{q(\phi^{G+1} | \phi^G)} = \frac{p(Y_{\text{new}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)}{p(Y_{\text{old}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)}$$

Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold Y^*
(z. B. den Durchschnitt oder den Median der Werte S_t)
- B. Gibbs-Sampling: Wiederhole die Schritte
1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :
 - Beobachtung: Ist Y^* bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime $S_t \leq Y^*$, eines für $S_t > Y^*$.
 - Seien $Y_{1,t}, X_{1,t}$ die zum Regime $S_t \leq Y^*$ und $Y_{2,t}, X_{2,t}$ die zum Regime $S_t > Y^*$ zugehörigen Daten.
 - Ziehe $b_1, b_2, \Omega_1, \Omega_2$ aus der Posterior-Verteilung $p(b_i | \Omega_i, Y_{i,t}), p(\Omega_i, Y_{i,t})$.
 2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für Y^* aus:
 - Generiere einen Kandidaten Y_{new}^* durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit $\alpha = \min(1, r)$ mit

$$\begin{aligned} r &= \frac{\pi(\phi^{G+1})}{\pi(\phi^G)} \cdot \frac{q(\phi^G | \phi^{G+1})}{q(\phi^{G+1} | \phi^G)} = \frac{p(Y_{\text{new}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)}{p(Y_{\text{old}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)} \\ &= \frac{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{new}}^*) \cdot p(Y_{\text{new}}^*)}{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{old}}^*) \cdot p(Y_{\text{old}}^*)} \end{aligned}$$

Bayessche Inferenz im Threshold-VAR-Modell

A. Initialisierung: Wähle einen Startwert für den Threshold Y^*

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :

- Seien $Y_{1,t}, X_{1,t}$ die zum Regime $S_t \leq Y^*$ und $Y_{2,t}, X_{2,t}$ die zum Regime $S_t > Y^*$ zugehörigen Daten.
- Ziehe $b_1, b_2, \Omega_1, \Omega_2$ aus der Posterior-Verteilung $p(b_i | \Omega_i, Y_{i,t}), p(\Omega_i, Y_{i,t})$.

2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für Y^* aus:

- Generiere einen Kandidaten Y_{new}^* durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit $\alpha = \min(1, r)$ mit

$$\begin{aligned} r &= \frac{\pi(\phi^{G+1})}{\pi(\phi^G)} \cdot \frac{q(\phi^G | \phi^{G+1})}{q(\phi^{G+1} | \phi^G)} = \frac{p(Y_{\text{new}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)}{p(Y_{\text{old}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)} \\ &= \frac{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{new}}^*) \cdot p(Y_{\text{new}}^*)}{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{old}}^*) \cdot p(Y_{\text{old}}^*)} \end{aligned}$$

Bayessche Inferenz im Threshold-VAR-Modell

A. Initialisierung: Wähle einen Startwert für den Threshold Y^*

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :

- Seien $Y_{1,t}$, $X_{1,t}$ die zum Regime $S_t \leq Y^*$ und $Y_{2,t}$, $X_{2,t}$ die zum Regime $S_t > Y^*$ zugehörigen Daten.
- Ziehe $b_1, b_2, \Omega_1, \Omega_2$ aus der Posterior-Verteilung $p(b_i | \Omega_i, Y_{i,t})$, $p(\Omega_i, Y_{i,t})$.

2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für Y^* aus:

- Generiere einen Kandidaten Y_{new}^* durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit $\alpha = \min(1, r)$ mit

$$\begin{aligned} r &= \frac{\pi(\phi^{G+1})}{\pi(\phi^G)} \cdot \frac{q(\phi^G | \phi^{G+1})}{q(\phi^{G+1} | \phi^G)} = \frac{p(Y_{\text{new}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)}{p(Y_{\text{old}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)} \\ &= \frac{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{new}}^*) \cdot p(Y_{\text{new}}^*)}{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{old}}^*) \cdot p(Y_{\text{old}}^*)} \end{aligned}$$

$$p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y^*) = p(Y_{1,t} | b_1, \Omega_1, Y^*) \cdot p(Y_{2,t} | b_2, \Omega_2, Y^*)$$

$$\log p(Y_{i,t} | b_i, \Omega_i, Y^*) = \frac{T}{2} \log |\Omega_i^{-1}| - \frac{1}{2} \sum_{t=1}^T (Y_{i,t} - X_{i,t} \tilde{b}_i)^T \Omega_i^{-1} (Y_{i,t} - X_{i,t} \tilde{b}_i)$$

Bayessche Inferenz im Threshold-VAR-Modell

A. Initialisierung: Wähle einen Startwert für den Threshold Y^*

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :

- Seien $Y_{1,t}$, $X_{1,t}$ die zum Regime $S_t \leq Y^*$ und $Y_{2,t}$, $X_{2,t}$ die zum Regime $S_t > Y^*$ zugehörigen Daten.
- Ziehe $b_1, b_2, \Omega_1, \Omega_2$ aus der Posterior-Verteilung $p(b_i | \Omega_i, Y_{i,t})$, $p(\Omega_i, Y_{i,t})$.

2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für Y^* aus:

- Generiere einen Kandidaten Y_{new}^* durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit $\alpha = \min(1, r)$ mit

$$\begin{aligned} r &= \frac{\pi(\phi^{G+1})}{\pi(\phi^G)} \cdot \frac{q(\phi^G | \phi^{G+1})}{q(\phi^{G+1} | \phi^G)} = \frac{p(Y_{\text{new}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)}{p(Y_{\text{old}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)} \\ &= \frac{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{new}}^*) \cdot p(Y_{\text{new}}^*)}{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{old}}^*) \cdot p(Y_{\text{old}}^*)} \end{aligned}$$

$$p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y^*) = p(Y_{1,t} | b_1, \Omega_1, Y^*) \cdot p(Y_{2,t} | b_2, \Omega_2, Y^*)$$

$$\log p(Y_{i,t} | b_i, \Omega_i, Y^*) = \frac{T}{2} \log |\Omega_i^{-1}| - \frac{1}{2} \sum_{t=1}^T (Y_{i,t} - X_{i,t} \tilde{b}_i)^T \Omega_i^{-1} (Y_{i,t} - X_{i,t} \tilde{b}_i)$$

- Ziehe $u \sim \mathcal{U}(0, 1)$. Behalte Y_{new}^* , falls $u < \alpha$, ansonsten verwirfe Y_{new}^* .

Bayessche Inferenz im Threshold-VAR-Modell

A. Initialisierung: Wähle einen Startwert für den Threshold Y^*

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample die **VAR-Parameter** gegeben dem Threshold Y^* :

- Seien $Y_{1,t}$, $X_{1,t}$ die zum Regime $S_t \leq Y^*$ und $Y_{2,t}$, $X_{2,t}$ die zum Regime $S_t > Y^*$ zugehörigen Daten.
- Ziehe $b_1, b_2, \Omega_1, \Omega_2$ aus der Posterior-Verteilung $p(b_i | \Omega_i, Y_{i,t})$, $p(\Omega_i, Y_{i,t})$.

2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für Y^* aus:

- Generiere einen Kandidaten Y_{new}^* durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit $\alpha = \min(1, r)$ mit

$$r = \frac{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{new}}^*) \cdot p(Y_{\text{new}}^*)}{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{old}}^*) \cdot p(Y_{\text{old}}^*)}$$

$$p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y^*) = p(Y_{1,t} | b_1, \Omega_1, Y^*) \cdot p(Y_{2,t} | b_2, \Omega_2, Y^*)$$

$$\log p(Y_{i,t} | b_i, \Omega_i, Y^*) = \frac{T}{2} \log |\Omega_i^{-1}| - \frac{1}{2} \sum_{t=1}^T (Y_{i,t} - X_{i,t} \tilde{b}_i)^T \Omega_i^{-1} (Y_{i,t} - X_{i,t} \tilde{b}_i)$$

- Ziehe $u \sim \mathcal{U}(0, 1)$. Behalte Y_{new}^* , falls $u < \alpha$, ansonsten verwurfe Y_{new}^* .

Metropolis-Hastings mit unabhängiger Kandidatenvert.

Ziel: Ziehen von Zahlen gemäß einer Dichte $\pi(\Phi)$

Metropolis-Hastings mit unabhängiger Kandidatenvert.

Ziel: Ziehen von Zahlen gemäß einer Dichte $\pi(\Phi)$

Erinnerung: Beim Metropolis-Hastings-Algorithmus zieht man zunächst einen Kandidaten gemäß der Kandidatenverteilung

$$q(\Phi^{G+1} | \Phi^G)$$

Dann berechnet man die Akzeptanzwahrscheinlichkeit $\alpha = \min(1, r)$ mit

$$r := \frac{\pi(\Phi^{G+1})/q(\Phi^{G+1} | \Phi^G)}{\pi(\Phi^G)/q(\Phi^G | \Phi^{G+1})}$$

Zuletzt zieht man $u \sim \mathcal{U}(0, 1)$ und man behält Φ^{G+1} , falls $u < \alpha$. Ansonsten verwirft man Φ^{G+1} . **TODO: Sprache mit verwerfen ein wenig anpassen.**

Metropolis-Hastings mit unabhängiger Kandidatenvert.

Ziel: Ziehen von Zahlen gemäß einer Dichte $\pi(\Phi) \propto f(\Phi) \cdot g(\Phi)$
(wobei f eine wohlbekannte Wahrscheinlichkeitsdichte ist)

Erinnerung: Beim Metropolis-Hastings-Algorithmus zieht man zunächst einen Kandidaten gemäß der Kandidatenverteilung

$$q(\Phi^{G+1} | \Phi^G)$$

Dann berechnet man die Akzeptanzwahrscheinlichkeit $\alpha = \min(1, r)$ mit

$$r := \frac{\pi(\Phi^{G+1})/q(\Phi^{G+1} | \Phi^G)}{\pi(\Phi^G)/q(\Phi^G | \Phi^{G+1})}$$

Zuletzt zieht man $u \sim \mathcal{U}(0, 1)$ und man behält Φ^{G+1} , falls $u < \alpha$. Ansonsten verwirft man Φ^{G+1} . **TODO: Sprache mit werfen ein wenig anpassen.**

Metropolis-Hastings mit unabhängiger Kandidatenvert.

Ziel: Ziehen von Zahlen gemäß einer Dichte $\pi(\Phi) \propto f(\Phi) \cdot g(\Phi)$
(wobei f eine wohlbekannte Wahrscheinlichkeitsdichte ist)

Erinnerung: Beim Metropolis-Hastings-Algorithmus zieht man zunächst einen Kandidaten gemäß der Kandidatenverteilung

$$q(\Phi^{G+1} | \Phi^G) := f(\Phi^{G+1}) \quad (\text{unabhängig von } \Phi^G!)$$

Dann berechnet man die Akzeptanzwahrscheinlichkeit $\alpha = \min(1, r)$ mit

$$r := \frac{\pi(\Phi^{G+1})/q(\Phi^{G+1} | \Phi^G)}{\pi(\Phi^G)/q(\Phi^G | \Phi^{G+1})}$$

Zuletzt zieht man $u \sim \mathcal{U}(0, 1)$ und man behält Φ^{G+1} , falls $u < \alpha$. Ansonsten verwirft man Φ^{G+1} . **TODO: Sprache mit verwerfen ein wenig anpassen.**

Metropolis-Hastings mit unabhängiger Kandidatenvert.

Ziel: Ziehen von Zahlen gemäß einer Dichte $\pi(\Phi) \propto f(\Phi) \cdot g(\Phi)$
(wobei f eine wohlbekannte Wahrscheinlichkeitsdichte ist)

Erinnerung: Beim Metropolis-Hastings-Algorithmus zieht man zunächst einen Kandidaten gemäß der Kandidatenverteilung

$$q(\Phi^{G+1} | \Phi^G) := f(\Phi^{G+1}) \quad (\text{unabhängig von } \Phi^G!)$$

Dann berechnet man die Akzeptanzwahrscheinlichkeit $\alpha = \min(1, r)$ mit

$$r := \frac{\pi(\Phi^{G+1})/q(\Phi^{G+1} | \Phi^G)}{\pi(\Phi^G)/q(\Phi^G | \Phi^{G+1})} = \frac{f(\Phi^{G+1}) \cdot g(\Phi^{G+1})/f(\Phi^{G+1})}{f(\Phi^G) \cdot g(\Phi^G)/f(\Phi^G)}$$

Zuletzt zieht man $u \sim \mathcal{U}(0, 1)$ und man behält Φ^{G+1} , falls $u < \alpha$. Ansonsten verwirft man Φ^{G+1} . **TODO: Sprache mit verwerfen ein wenig anpassen.**

Metropolis-Hastings mit unabhängiger Kandidatenvert.

Ziel: Ziehen von Zahlen gemäß einer Dichte $\pi(\Phi) \propto f(\Phi) \cdot g(\Phi)$
(wobei f eine wohlbekannte Wahrscheinlichkeitsdichte ist)

Erinnerung: Beim Metropolis-Hastings-Algorithmus zieht man zunächst einen Kandidaten gemäß der Kandidatenverteilung

$$q(\Phi^{G+1} | \Phi^G) := f(\Phi^{G+1}) \quad (\text{unabhängig von } \Phi^G!)$$

Dann berechnet man die Akzeptanzwahrscheinlichkeit $\alpha = \min(1, r)$ mit

$$r := \frac{\pi(\Phi^{G+1})/q(\Phi^{G+1} | \Phi^G)}{\pi(\Phi^G)/q(\Phi^G | \Phi^{G+1})} = \frac{f(\Phi^{G+1}) \cdot g(\Phi^{G+1})/f(\Phi^{G+1})}{f(\Phi^G) \cdot g(\Phi^G)/f(\Phi^G)} = \frac{g(\Phi^{G+1})}{g(\Phi^G)}$$

Zuletzt zieht man $u \sim \mathcal{U}(0, 1)$ und man behält Φ^{G+1} , falls $u < \alpha$. Ansonsten verwirft man Φ^{G+1} . **TODO: Sprache mit verwerfen ein wenig anpassen.**

Das stochastische Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T & \text{(Beobachtungsgl.)} \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T & \text{(Zustandsgl.)} \end{aligned}$$

Das stochastische Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), & t &= 1, \dots, T & \quad (\text{Beobachtungsgl.}) \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), & t &= 1, \dots, T & \quad (\text{Zustandsgl.}) \end{aligned}$$

Beispiel

TODO: Aktien? Graphik?

Bayesische Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned}y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T\end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte t , außer Start- und Endzeitpunkt, gilt:

$$f(h_t | h_{-t}, \vec{y}, g) = f(h_t | h_{t-1}, h_{t+1}, y_t, g)$$

TODO: Behandlung von h_T

Bayesische Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned}y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T\end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte t , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned}f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g)\end{aligned}$$

TODO: Behandlung von h_T

Bayesische Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte t , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g) \end{aligned}$$

Nebenrechnung

$$\begin{aligned} f(y_t | h_t) &= \frac{1}{\sqrt{2\pi h_t}} \exp\left(\frac{-y_t^2}{2h_t}\right) && \text{(Normalverteilung)} \\ f(h_{t+1} | h_t) &= \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{h_{t+1}} \exp\left(\frac{-(\ln h_{t+1} - \ln h_t)^2}{2g}\right) && \text{(Log. Normalvert.)} \\ f(h_t | h_{t-1}) &= \frac{1}{\sqrt{2\pi}} \frac{1}{h_t} \exp\left(\frac{-(\ln h_t - \ln h_{t-1})^2}{2g}\right) && \text{(Log. Normalvert.)} \end{aligned}$$

TODO: Behandlung von h_T

Bayesische Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte t , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g) \\ &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu)^2}{2\sigma_h}\right) \\ &\quad \text{mit } \mu := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_h := \frac{1}{2}g \end{aligned}$$

Nebenrechnung

$$\begin{aligned} f(y_t | h_t) &= \frac{1}{\sqrt{2\pi h_t}} \exp\left(\frac{-y_t^2}{2h_t}\right) && \text{(Normalverteilung)} \\ f(h_{t+1} | h_t) &= \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{h_{t+1}} \exp\left(\frac{-(\ln h_{t+1} - \ln h_t)^2}{2g}\right) && \text{(Log. Normalvert.)} \\ f(h_t | h_{t-1}) &= \frac{1}{\sqrt{2\pi}} \frac{1}{h_t} \exp\left(\frac{-(\ln h_t - \ln h_{t-1})^2}{2g}\right) && \text{(Log. Normalvert.)} \end{aligned}$$

TODO: Behandlung von h_T

Bayesische Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte t , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g) \\ &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu)^2}{2\sigma_h}\right) \\ &\quad \text{mit } \mu := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_h := \frac{1}{2}g \end{aligned}$$

TODO: Behandlung von h_T

Bayesische Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte t , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g) \\ &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu)^2}{2\sigma_h}\right) \\ &\quad \text{mit } \mu := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_h := \frac{1}{2}g \end{aligned}$$

Wir erfinden eine weitere Volatilitätsvariable h_0 hinzu. Diese habe die Prior-Verteilung $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$. **TODO: Behandlung von h_T**

Bayesische Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte t , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g) \\ &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu)^2}{2\sigma_h}\right) \\ &\quad \text{mit } \mu := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_h := \frac{1}{2}g \end{aligned}$$

Wir erfinden eine weitere Volatilitätsvariable h_0 hinzu. Diese habe die Prior-Verteilung $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$. Für den Posterior gilt:

$$\begin{aligned} f(h_0 | h_1) &\propto f(h_0) \cdot f(h_1 | h_0) \\ &\propto \frac{1}{\sqrt{\bar{\sigma}^2}} \exp\left(-\frac{(h_0 - \bar{\mu})^2}{2\bar{\sigma}^2}\right) \cdot \frac{1}{h_0} \exp\left(-\frac{(\ln h_1 - \ln h_0)^2}{2g}\right) \end{aligned}$$

TODO: Behandlung von h_T

Bayesische Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte t , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g) \\ &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu)^2}{2\sigma_h}\right) \\ &\quad \text{mit } \mu := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_h := \frac{1}{2}g \end{aligned}$$

Wir erfinden eine weitere Volatilitätsvariable h_0 hinzu. Diese habe die Prior-Verteilung $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$. Für den Posterior gilt:

$$\begin{aligned} f(h_0 | h_1) &\propto f(h_0) \cdot f(h_1 | h_0) \\ &\propto \frac{1}{\sqrt{\bar{\sigma}^2}} \exp\left(-\frac{(h_0 - \bar{\mu})^2}{2\bar{\sigma}^2}\right) \cdot \frac{1}{h_0} \exp\left(-\frac{-(\ln h_1 - \ln h_0)^2}{2g}\right) \\ &\propto h_0^{-1} \end{aligned}$$

TODO: Behandlung von h_T

Bayesische Inferenz im stochastischen Volatilitätsmodell

- A. Setze die Parameter der Prior-Vert. $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$ sowie $g \sim \mathcal{IG}(\frac{g_0}{2}, \frac{\nu}{2})$
- B. Initialisierung: Wähle Startwerte für h_0, \dots, h_T und g
- C. Gibbs-Sampling: Wiederhole die Schritte
 1. **TODO:** $t = 0$
 2. Für $t = 1, \dots, T - 1$ ziehe einen Kandidaten gemäß

$$q(h_{t,\text{new}}) = h_{t,\text{new}}^{-1} \exp\left(\frac{-(\ln h_{t,\text{new}} - \mu)^2}{2\sigma_h}\right), \quad \mu := \frac{\ln h_{t-1} + \ln h_{t+1}}{2}, \quad \sigma_h := \frac{g}{2}.$$

Berechne die Akzeptanz-Wahrscheinlichkeit $\alpha = \min(1, r)$ mit

$$r := \frac{\frac{1}{\sqrt{h_{t,\text{new}}}} \exp\left(\frac{-y_t^2}{2h_{t,\text{new}}}\right)}{\frac{1}{\sqrt{h_{t,\text{old}}}} \exp\left(\frac{-y_t^2}{2h_{t,\text{old}}}\right)}$$

Ziehe $u \sim \mathcal{U}(0, 1)$. Behalte $h_{t,\text{new}}$, falls $u < \alpha$, ansonsten verwirfe $h_{t,\text{new}}$.

3. **TODO:** $T = t$
- 4.

Erweiterte Version des stochastischen Volatilitätsmodells

$$\begin{aligned} y_t &= c_t + b_t y_{t-1} + \epsilon_t \sqrt{h_t}, \quad \epsilon_t \sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, \quad v_t \sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Für die Regressions-Koeffizienten $B_t = \{c_t, b_t\}$ gelte dabei

$$B_t = B_{t-1} + e_t, \quad e_t \sim \mathcal{N}(0, Q), \quad Q \in \mathbb{R}^{2 \times 2}.$$

TODO: Motivation

Bayessche Inferenz im erw. stoch. Volatilitätsmodell

- A. Initialisierung: Wähle Startwerte für **TODO: ???**
- B. Gibbs-Sampling: Wiederhole die Schritte
 1. Sample h_0, \dots, h_T gegeben g und B_1, \dots, B_T : Für $t = 1, \dots, T - 1$ führe einen MH-Schritt für h_t aus