

# Gibbs-Sampling mit Metropolis-Hastings-Schritt für Threshold-VAR-Modelle und stochastische Volatilitätsmodelle

Tim Baumann

[timbaumann.info/gibbs-her](http://timbaumann.info/gibbs-her)

29. April 2016

- ① Das Threshold-VAR-Modell  
Bayessche Inferenz (mit Random-Walk-MH)
- ② Metropolis-Hastings mit unabhängiger Kandidatenverteilung
- ③ Das stochastische Volatilitätsmodell  
Bayessche Inferenz (mit unabhängigem MH)
- ④ Erweiterte Version des stochastischen Volatilitätsmodells  
Bayessche Inferenz (mit unabhängigem MH)

# Das Threshold-VAR-Modell

$$(TVAR) \quad \begin{cases} Y_t = c_1 + \sum_{j=1}^P \beta_1 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_1 & \text{wenn } S_t \leq Y^* \\ Y_t = c_2 + \sum_{j=1}^P \beta_2 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_2 & \text{wenn } S_t > Y^* \end{cases}$$

wobei  $S_t := Y_{j,t-d}$  (*Threshold-Variable*)

$$Y_t, v_t, c_1, c_2 \in \mathbb{R}^N, \quad \beta_1, \beta_2 \in \mathbb{R}^{N \times N}, \quad \Omega_1, \Omega_2 \in \mathbb{R}^{N \times N}, \quad Y^* \in \mathbb{R}$$

Dabei wird die Threshold-Komponente  $j$  von  $Y$  und die Verzögerung  $d$  vom Anwender gewählt.

# Das Threshold-VAR-Modell

$$(TVAR) \quad \begin{cases} Y_t = c_1 + \sum_{j=1}^P \beta_1 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_1 & \text{wenn } S_t \leq Y^* \\ Y_t = c_2 + \sum_{j=1}^P \beta_2 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_2 & \text{wenn } S_t > Y^* \end{cases}$$

wobei  $S_t := Y_{j,t-d}$  (*Threshold-Variable*)

$$Y_t, v_t, c_1, c_2 \in \mathbb{R}^N, \quad \beta_1, \beta_2 \in \mathbb{R}^{N \times N}, \quad \Omega_1, \Omega_2 \in \mathbb{R}^{N \times N}, \quad Y^* \in \mathbb{R}$$

Dabei wird die Threshold-Komponente  $j$  von  $Y$  und die Verzögerung  $d$  vom Anwender gewählt.

## Beispiel

Makroökonomische Modellierung, wobei vermutet wird, dass die Stärke wirtschaftlicher Zusammenhänge (z. B. Multiplikator für Staatsausgaben) in Wirtschaftskrisen unterschiedlich groß ist wie in wirtschaftlich normalen oder guten Zeiten.

# Bayessche Inferenz im Threshold-VAR-Modell

$$\text{(TVAR)} \quad \begin{cases} Y_t = \mathbf{c}_1 + \sum_{j=1}^P \beta_1 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_1 & \text{wenn } S_t \leq Y^* \\ Y_t = \mathbf{c}_2 + \sum_{j=1}^P \beta_2 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_2 & \text{wenn } S_t > Y^* \end{cases}$$

wobei  $S_t := Y_{j,t-d}$  (*Threshold-Variable*)

# Bayessche Inferenz im Threshold-VAR-Modell

$$\text{(TVAR)} \quad \begin{cases} Y_t = c_1 + \sum_{j=1}^P \beta_1 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_1 & \text{wenn } S_t \leq Y^* \\ Y_t = c_2 + \sum_{j=1}^P \beta_2 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_2 & \text{wenn } S_t > Y^* \end{cases}$$

wobei  $S_t := Y_{j,t-d}$  (*Threshold-Variable*)

## Prior-Verteilung

# Bayessche Inferenz im Threshold-VAR-Modell

$$\text{(TVAR)} \quad \begin{cases} Y_t = c_1 + \sum_{j=1}^P \beta_1 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_1 & \text{wenn } S_t \leq Y^* \\ Y_t = c_2 + \sum_{j=1}^P \beta_2 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_2 & \text{wenn } S_t > Y^* \end{cases}$$

wobei  $S_t := Y_{j,t-d}$  (*Threshold-Variable*)

## Prior-Verteilung

- Für den Threshold:  $p(Y^*) \sim \mathcal{N}(\bar{Y}^*, \sigma_{Y^*})$

# Bayessche Inferenz im Threshold-VAR-Modell

$$\begin{aligned}
 (\text{TVAR}) \quad & \begin{cases} Y_t = \mathbf{c}_1 + \sum_{j=1}^P \beta_1 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_1 & \text{wenn } S_t \leq Y^* \\ Y_t = \mathbf{c}_2 + \sum_{j=1}^P \beta_2 Y_{t-j} + v_t, & \text{Var}(v_t) = \Omega_2 & \text{wenn } S_t > Y^* \end{cases} \\
 & \text{wobei } S_t := Y_{j,t-d} \text{ (Threshold-Variable)}
 \end{aligned}$$

## Prior-Verteilung

- Für den Threshold:  $p(Y^*) \sim \mathcal{N}(\bar{Y}^*, \sigma_{Y^*})$
- Für die VAR-Parameter  $\mathbf{b}_1, \mathbf{b}_2 \in \mathbb{R}^{(1+NP) \cdot N}$  und  $\Omega_1, \Omega_2 \in \mathbb{R}^{N \times N}$  verwenden wir die Normal-Inverse-Wishart-Verteilung mit Dummy-Observations  $X_{D,i} \in \mathbb{R}^{k_i \times (1+NP)}$ ,  $Y_{D,i} \in \mathbb{R}^{k_i \times N}$  ( $i = 1, 2$ ):

$$\begin{aligned}
 p(\mathbf{b}_i | \Omega_i) &\sim \mathcal{N}(\text{vec}(B_{D,i}), \Omega_i \otimes (X_{D,i}^T X_{D,i})^{-1}), \\
 p(\Omega_i) &\sim \mathcal{IW}(S_{D,i}, \text{TODO : } T_{D,i} - ???)
 \end{aligned}$$

$$\begin{aligned}
 \text{wobei} \quad B_{D,i} &:= (X_{D,i}^T X_{D,i})^{-1} (X_{D,i} Y_{D,i}) \in \mathbb{R}^{(1+NP) \times N} \\
 S_{D,i} &:= (Y_{D,i} - X_{D,i} B_{D,i})^T (Y_{D,i} - X_{D,i} B_{D,i}) \in \mathbb{R}^{N \times N}
 \end{aligned}$$



# Bayessche Inferenz im Threshold-VAR-Modell

# Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold  $\gamma^*$   
(z. B. den Durchschnitt oder den Median der Werte  $S_t$ )

# Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Treshold  $Y^*$   
(z. B. den Durschnitt oder den Median der Werte  $S_t$ )
- B. Gibbs-Sampling: Wiederhole die Schritte

# Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$   
(z. B. den Durchschnitt oder den Median der Werte  $S_t$ )
- B. Gibbs-Sampling: Wiederhole die Schritte
  1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :

# Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$   
(z. B. den Durchschnitt oder den Median der Werte  $S_t$ )
- B. Gibbs-Sampling: Wiederhole die Schritte
  1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :
    - Beobachtung: Ist  $Y^*$  bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime  $S_t \leq Y^*$ , eines für  $S_t > Y^*$ .

# Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$   
(z. B. den Durchschnitt oder den Median der Werte  $S_t$ )
- B. Gibbs-Sampling: Wiederhole die Schritte
1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :
    - Beobachtung: Ist  $Y^*$  bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime  $S_t \leq Y^*$ , eines für  $S_t > Y^*$ .
    - Seien  $Y_{1,t}$ ,  $X_{1,t}$  die zum Regime  $S_t \leq Y^*$  und  $Y_{2,t}$ ,  $X_{2,t}$  die zum Regime  $S_t > Y^*$  zugehörigen Daten.

# Bayessche Inferenz im Threshold-VAR-Modell

A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$

(z. B. den Durchschnitt oder den Median der Werte  $S_t$ )

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :

- Beobachtung: Ist  $Y^*$  bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime  $S_t \leq Y^*$ , eines für  $S_t > Y^*$ .
- Seien  $Y_{1,t}$ ,  $X_{1,t}$  die zum Regime  $S_t \leq Y^*$  und  $Y_{2,t}$ ,  $X_{2,t}$  die zum Regime  $S_t > Y^*$  zugehörigen Daten.
- Ziehe  $b_1$ ,  $b_2$ ,  $\Omega_1$ ,  $\Omega_2$  aus der Posterior-Verteilung

$$\begin{aligned} p(b_i | \Omega_i, Y_{i,t}) &\sim \mathcal{N}(\text{vec}(B_i^*), \Omega_i \otimes ((X_i^*)^T X_i^*)^{-1}), \\ p(\Omega_i, Y_{i,t}) &\sim \mathcal{IW}(S_i^*, \text{TODO} : T_i^* - ???) \end{aligned}$$

$$\begin{aligned} \text{wobei } B_i^* &:= ((X_i^*)^T X_i^*)^{-1} (X_i^{*T} Y_i^*) \\ S_i^* &:= (Y_i^* - X_i^{*T} B_i^*)^T (Y_i^* - X_i^{*T} B_i^*) \\ Y_i^* &:= [Y_{i,t}, Y_{D,i}] \\ X_i^* &:= [X_{i,t}, X_{D,i}] \end{aligned}$$

# Bayessche Inferenz im Threshold-VAR-Modell

A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$

(z. B. den Durchschnitt oder den Median der Werte  $S_t$ )

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :

- Beobachtung: Ist  $Y^*$  bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime  $S_t \leq Y^*$ , eines für  $S_t > Y^*$ .
- Seien  $Y_{1,t}, X_{1,t}$  die zum Regime  $S_t \leq Y^*$  und  $Y_{2,t}, X_{2,t}$  die zum Regime  $S_t > Y^*$  zugehörigen Daten.
- Ziehe  $b_1, b_2, \Omega_1, \Omega_2$  aus der Posterior-Verteilung

$$\begin{aligned} p(b_i | \Omega_i, Y_{i,t}) &\sim \mathcal{N}(\text{vec}(B_i^*), \Omega_i \otimes ((X_i^*)^T X_i^*)^{-1}), \\ p(\Omega_i, Y_{i,t}) &\sim \mathcal{IW}(S_i^*, \text{TODO : } T_i^* - ???) \end{aligned}$$

$$\begin{aligned} \text{wobei } B_i^* &:= ((X_i^*)^T X_i^*)^{-1} (X_i^{*T} Y_i^*) \\ S_i^* &:= (Y_i^* - X_i^{*T} B_i^*)^T (Y_i^* - X_i^{*T} B_i^*) \\ Y_i^* &:= [Y_{i,t}, Y_{D,i}] \\ X_i^* &:= [X_{i,t}, X_{D,i}] \end{aligned}$$

2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für  $Y^*$  aus:



# Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$   
(z. B. den Durchschnitt oder den Median der Werte  $S_t$ )
- B. Gibbs-Sampling: Wiederhole die Schritte
1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :
    - Beobachtung: Ist  $Y^*$  bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime  $S_t \leq Y^*$ , eines für  $S_t > Y^*$ .
    - Seien  $Y_{1,t}, X_{1,t}$  die zum Regime  $S_t \leq Y^*$  und  $Y_{2,t}, X_{2,t}$  die zum Regime  $S_t > Y^*$  zugehörigen Daten.
    - Ziehe  $b_1, b_2, \Omega_1, \Omega_2$  aus der Posterior-Verteilung  $p(b_i | \Omega_i, Y_{i,t})$ ,  $p(\Omega_i, Y_{i,t})$ .
  2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für  $Y^*$  aus:

# Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$   
(z. B. den Durchschnitt oder den Median der Werte  $S_t$ )
- B. Gibbs-Sampling: Wiederhole die Schritte
1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :
    - Beobachtung: Ist  $Y^*$  bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime  $S_t \leq Y^*$ , eines für  $S_t > Y^*$ .
    - Seien  $Y_{1,t}$ ,  $X_{1,t}$  die zum Regime  $S_t \leq Y^*$  und  $Y_{2,t}$ ,  $X_{2,t}$  die zum Regime  $S_t > Y^*$  zugehörigen Daten.
    - Ziehe  $b_1, b_2, \Omega_1, \Omega_2$  aus der Posterior-Verteilung  $p(b_i | \Omega_i, Y_{i,t})$ ,  $p(\Omega_i, Y_{i,t})$ .
  2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für  $Y^*$  aus:
    - Generiere einen Kandidaten  $Y_{\text{new}}^*$  durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

# Bayessche Inferenz im Threshold-VAR-Modell

A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$   
(z. B. den Durchschnitt oder den Median der Werte  $S_t$ )

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :

- Beobachtung: Ist  $Y^*$  bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime  $S_t \leq Y^*$ , eines für  $S_t > Y^*$ .
- Seien  $Y_{1,t}$ ,  $X_{1,t}$  die zum Regime  $S_t \leq Y^*$  und  $Y_{2,t}$ ,  $X_{2,t}$  die zum Regime  $S_t > Y^*$  zugehörigen Daten.
- Ziehe  $b_1, b_2, \Omega_1, \Omega_2$  aus der Posterior-Verteilung  $p(b_i | \Omega_i, Y_{i,t})$ ,  $p(\Omega_i, Y_{i,t})$ .

2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für  $Y^*$  aus:

- Generiere einen Kandidaten  $Y_{\text{new}}^*$  durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$r = \frac{\pi(\phi^{G+1})}{\pi(\phi^G)} \cdot \frac{q(\phi^G | \phi^{G+1})}{q(\phi^{G+1} | \phi^G)}$$

# Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$   
(z. B. den Durchschnitt oder den Median der Werte  $S_t$ )
- B. Gibbs-Sampling: Wiederhole die Schritte
1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :
    - Beobachtung: Ist  $Y^*$  bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime  $S_t \leq Y^*$ , eines für  $S_t > Y^*$ .
    - Seien  $Y_{1,t}, X_{1,t}$  die zum Regime  $S_t \leq Y^*$  und  $Y_{2,t}, X_{2,t}$  die zum Regime  $S_t > Y^*$  zugehörigen Daten.
    - Ziehe  $b_1, b_2, \Omega_1, \Omega_2$  aus der Posterior-Verteilung  $p(b_i | \Omega_i, Y_{i,t}), p(\Omega_i, Y_{i,t})$ .
  2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für  $Y^*$  aus:
    - Generiere einen Kandidaten  $Y_{\text{new}}^*$  durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$r = \frac{\pi(\phi^{G+1})}{\pi(\phi^G)} \cdot \frac{q(\phi^G | \phi^{G+1})}{q(\phi^{G+1} | \phi^G)} = \frac{p(Y_{\text{new}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)}{p(Y_{\text{old}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)}$$

# Bayessche Inferenz im Threshold-VAR-Modell

- A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$   
(z. B. den Durchschnitt oder den Median der Werte  $S_t$ )
- B. Gibbs-Sampling: Wiederhole die Schritte
1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :
    - Beobachtung: Ist  $Y^*$  bekannt, so zerfällt das Modell in zwei einfache VAR-Modelle, eines für das Regime  $S_t \leq Y^*$ , eines für  $S_t > Y^*$ .
    - Seien  $Y_{1,t}, X_{1,t}$  die zum Regime  $S_t \leq Y^*$  und  $Y_{2,t}, X_{2,t}$  die zum Regime  $S_t > Y^*$  zugehörigen Daten.
    - Ziehe  $b_1, b_2, \Omega_1, \Omega_2$  aus der Posterior-Verteilung  $p(b_i | \Omega_i, Y_{i,t}), p(\Omega_i, Y_{i,t})$ .
  2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für  $Y^*$  aus:
    - Generiere einen Kandidaten  $Y_{\text{new}}^*$  durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$\begin{aligned} r &= \frac{\pi(\phi^{G+1})}{\pi(\phi^G)} \cdot \frac{q(\phi^G | \phi^{G+1})}{q(\phi^{G+1} | \phi^G)} = \frac{p(Y_{\text{new}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)}{p(Y_{\text{old}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)} \\ &= \frac{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{new}}^*) \cdot p(Y_{\text{new}}^*)}{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{old}}^*) \cdot p(Y_{\text{old}}^*)} \end{aligned}$$

# Bayessche Inferenz im Threshold-VAR-Modell

A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :

- Seien  $Y_{1,t}, X_{1,t}$  die zum Regime  $S_t \leq Y^*$  und  $Y_{2,t}, X_{2,t}$  die zum Regime  $S_t > Y^*$  zugehörigen Daten.
- Ziehe  $b_1, b_2, \Omega_1, \Omega_2$  aus der Posterior-Verteilung  $p(b_i | \Omega_i, Y_{i,t}), p(\Omega_i, Y_{i,t})$ .

2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für  $Y^*$  aus:

- Generiere einen Kandidaten  $Y_{\text{new}}^*$  durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$\begin{aligned} r &= \frac{\pi(\phi^{G+1})}{\pi(\phi^G)} \cdot \frac{q(\phi^G | \phi^{G+1})}{q(\phi^{G+1} | \phi^G)} = \frac{p(Y_{\text{new}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)}{p(Y_{\text{old}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)} \\ &= \frac{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{new}}^*) \cdot p(Y_{\text{new}}^*)}{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{old}}^*) \cdot p(Y_{\text{old}}^*)} \end{aligned}$$

# Bayessche Inferenz im Threshold-VAR-Modell

A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :

- Seien  $Y_{1,t}$ ,  $X_{1,t}$  die zum Regime  $S_t \leq Y^*$  und  $Y_{2,t}$ ,  $X_{2,t}$  die zum Regime  $S_t > Y^*$  zugehörigen Daten.
- Ziehe  $b_1, b_2, \Omega_1, \Omega_2$  aus der Posterior-Verteilung  $p(b_i | \Omega_i, Y_{i,t})$ ,  $p(\Omega_i, Y_{i,t})$ .

2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für  $Y^*$  aus:

- Generiere einen Kandidaten  $Y_{\text{new}}^*$  durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$\begin{aligned} r &= \frac{\pi(\phi^{G+1})}{\pi(\phi^G)} \cdot \frac{q(\phi^G | \phi^{G+1})}{q(\phi^{G+1} | \phi^G)} = \frac{p(Y_{\text{new}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)}{p(Y_{\text{old}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)} \\ &= \frac{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{new}}^*) \cdot p(Y_{\text{new}}^*)}{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{old}}^*) \cdot p(Y_{\text{old}}^*)} \end{aligned}$$

$$p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y^*) = p(Y_{1,t} | b_1, \Omega_1, Y^*) \cdot p(Y_{2,t} | b_2, \Omega_2, Y^*)$$

$$\log p(Y_{i,t} | b_i, \Omega_i, Y^*) = \frac{T}{2} \log |\Omega_i^{-1}| - \frac{1}{2} \sum_{t=1}^T (Y_{i,t} - X_{i,t} \tilde{b}_i)^T \Omega_i^{-1} (Y_{i,t} - X_{i,t} \tilde{b}_i)$$

# Bayessche Inferenz im Threshold-VAR-Modell

A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :

- Seien  $Y_{1,t}$ ,  $X_{1,t}$  die zum Regime  $S_t \leq Y^*$  und  $Y_{2,t}$ ,  $X_{2,t}$  die zum Regime  $S_t > Y^*$  zugehörigen Daten.
- Ziehe  $b_1, b_2, \Omega_1, \Omega_2$  aus der Posterior-Verteilung  $p(b_i | \Omega_i, Y_{i,t})$ ,  $p(\Omega_i, Y_{i,t})$ .

2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für  $Y^*$  aus:

- Generiere einen Kandidaten  $Y_{\text{new}}^*$  durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$\begin{aligned} r &= \frac{\pi(\phi^{G+1})}{\pi(\phi^G)} \cdot \frac{q(\phi^G | \phi^{G+1})}{q(\phi^{G+1} | \phi^G)} = \frac{p(Y_{\text{new}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)}{p(Y_{\text{old}}^* | b_1, \Omega_1, b_2, \Omega_2, Y_t)} \\ &= \frac{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{new}}^*) \cdot p(Y_{\text{new}}^*)}{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{old}}^*) \cdot p(Y_{\text{old}}^*)} \end{aligned}$$

$$p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y^*) = p(Y_{1,t} | b_1, \Omega_1, Y^*) \cdot p(Y_{2,t} | b_2, \Omega_2, Y^*)$$

$$\log p(Y_{i,t} | b_i, \Omega_i, Y^*) = \frac{T}{2} \log |\Omega_i^{-1}| - \frac{1}{2} \sum_{t=1}^T (Y_{i,t} - X_{i,t} \tilde{b}_i)^T \Omega_i^{-1} (Y_{i,t} - X_{i,t} \tilde{b}_i)$$

- Ziehe  $u \sim \mathcal{U}(0, 1)$ . Behalte  $Y_{\text{new}}^*$ , falls  $u < \alpha$ , ansonsten verwirfe  $Y_{\text{new}}^*$ .



# Bayessche Inferenz im Threshold-VAR-Modell

A. Initialisierung: Wähle einen Startwert für den Threshold  $Y^*$

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample die **VAR-Parameter** gegeben dem Threshold  $Y^*$ :

- Seien  $Y_{1,t}$ ,  $X_{1,t}$  die zum Regime  $S_t \leq Y^*$  und  $Y_{2,t}$ ,  $X_{2,t}$  die zum Regime  $S_t > Y^*$  zugehörigen Daten.
- Ziehe  $b_1, b_2, \Omega_1, \Omega_2$  aus der Posterior-Verteilung  $p(b_i | \Omega_i, Y_{i,t})$ ,  $p(\Omega_i, Y_{i,t})$ .

2. Führe einen Random-Walk-Metropolis-Hastings-Schritt für  $Y^*$  aus:

- Generiere einen Kandidaten  $Y_{\text{new}}^*$  durch einen Random-Walk-Schritt:

$$Y_{\text{new}}^* := Y_{\text{old}}^* + e, \quad e \sim \mathcal{N}(0, \sigma)$$

- Berechne die Akzeptanz-Wahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$r = \frac{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{new}}^*) \cdot p(Y_{\text{new}}^*)}{p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y_{\text{old}}^*) \cdot p(Y_{\text{old}}^*)}$$

$$p(Y_t | b_1, \Omega_1, b_2, \Omega_2, Y^*) = p(Y_{1,t} | b_1, \Omega_1, Y^*) \cdot p(Y_{2,t} | b_2, \Omega_2, Y^*)$$

$$\log p(Y_{i,t} | b_i, \Omega_i, Y^*) = \frac{T}{2} \log |\Omega_i^{-1}| - \frac{1}{2} \sum_{t=1}^T (Y_{i,t} - X_{i,t} \tilde{b}_i)^T \Omega_i^{-1} (Y_{i,t} - X_{i,t} \tilde{b}_i)$$

- Ziehe  $u \sim \mathcal{U}(0, 1)$ . Behalte  $Y_{\text{new}}^*$ , falls  $u < \alpha$ , ansonsten verwurfe  $Y_{\text{new}}^*$ .

# Metropolis-Hastings mit unabhängiger Kandidatenvert.

**Ziel:** Ziehen von Zahlen gemäß einer Dichte  $\pi(\Phi)$

# Metropolis-Hastings mit unabhängiger Kandidatenvert.

**Ziel:** Ziehen von Zahlen gemäß einer Dichte  $\pi(\Phi)$

**Erinnerung:** Beim Metropolis-Hastings-Algorithmus zieht man zunächst einen Kandidaten gemäß der Kandidatenverteilung

$$q(\Phi^{G+1} | \Phi^G)$$

Dann berechnet man die Akzeptanzwahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$r := \frac{\pi(\Phi^{G+1})/q(\Phi^{G+1} | \Phi^G)}{\pi(\Phi^G)/q(\Phi^G | \Phi^{G+1})}$$

Zuletzt zieht man  $u \sim \mathcal{U}(0, 1)$  und man behält  $\Phi^{G+1}$ , falls  $u < \alpha$ . Ansonsten verwirft man  $\Phi^{G+1}$ . **TODO: Sprache mit verwerfen ein wenig anpassen.**

# Metropolis-Hastings mit unabhängiger Kandidatenvert.

**Ziel:** Ziehen von Zahlen gemäß einer Dichte  $\pi(\Phi) \propto f(\Phi) \cdot g(\Phi)$   
(wobei  $f$  eine wohlbekannte Wahrscheinlichkeitsdichte ist)

**Erinnerung:** Beim Metropolis-Hastings-Algorithmus zieht man zunächst einen Kandidaten gemäß der Kandidatenverteilung

$$q(\Phi^{G+1} | \Phi^G)$$

Dann berechnet man die Akzeptanzwahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$r := \frac{\pi(\Phi^{G+1})/q(\Phi^{G+1} | \Phi^G)}{\pi(\Phi^G)/q(\Phi^G | \Phi^{G+1})}$$

Zuletzt zieht man  $u \sim \mathcal{U}(0, 1)$  und man behält  $\Phi^{G+1}$ , falls  $u < \alpha$ . Ansonsten verwirft man  $\Phi^{G+1}$ . **TODO: Sprache mit werfen ein wenig anpassen.**

# Metropolis-Hastings mit unabhängiger Kandidatenvert.

**Ziel:** Ziehen von Zahlen gemäß einer Dichte  $\pi(\Phi) \propto f(\Phi) \cdot g(\Phi)$   
(wobei  $f$  eine wohlbekannte Wahrscheinlichkeitsdichte ist)

**Erinnerung:** Beim Metropolis-Hastings-Algorithmus zieht man zunächst einen Kandidaten gemäß der Kandidatenverteilung

$$q(\Phi^{G+1} | \Phi^G) := f(\Phi^{G+1}) \quad (\text{unabhängig von } \Phi^G!)$$

Dann berechnet man die Akzeptanzwahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$r := \frac{\pi(\Phi^{G+1})/q(\Phi^{G+1} | \Phi^G)}{\pi(\Phi^G)/q(\Phi^G | \Phi^{G+1})}$$

Zuletzt zieht man  $u \sim \mathcal{U}(0, 1)$  und man behält  $\Phi^{G+1}$ , falls  $u < \alpha$ . Ansonsten verwirft man  $\Phi^{G+1}$ . **TODO: Sprache mit verwerfen ein wenig anpassen.**

# Metropolis-Hastings mit unabhängiger Kandidatenvert.

**Ziel:** Ziehen von Zahlen gemäß einer Dichte  $\pi(\Phi) \propto f(\Phi) \cdot g(\Phi)$   
(wobei  $f$  eine wohlbekannte Wahrscheinlichkeitsdichte ist)

**Erinnerung:** Beim Metropolis-Hastings-Algorithmus zieht man zunächst einen Kandidaten gemäß der Kandidatenverteilung

$$q(\Phi^{G+1} | \Phi^G) := f(\Phi^{G+1}) \quad (\text{unabhängig von } \Phi^G!)$$

Dann berechnet man die Akzeptanzwahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$r := \frac{\pi(\Phi^{G+1})/q(\Phi^{G+1} | \Phi^G)}{\pi(\Phi^G)/q(\Phi^G | \Phi^{G+1})} = \frac{f(\Phi^{G+1}) \cdot g(\Phi^{G+1})/f(\Phi^{G+1})}{f(\Phi^G) \cdot g(\Phi^G)/f(\Phi^G)}$$

Zuletzt zieht man  $u \sim \mathcal{U}(0, 1)$  und man behält  $\Phi^{G+1}$ , falls  $u < \alpha$ . Ansonsten verwirft man  $\Phi^{G+1}$ . **TODO: Sprache mit verwerfen ein wenig anpassen.**

# Metropolis-Hastings mit unabhängiger Kandidatenvert.

**Ziel:** Ziehen von Zahlen gemäß einer Dichte  $\pi(\Phi) \propto f(\Phi) \cdot g(\Phi)$   
(wobei  $f$  eine wohlbekannte Wahrscheinlichkeitsdichte ist)

**Erinnerung:** Beim Metropolis-Hastings-Algorithmus zieht man zunächst einen Kandidaten gemäß der Kandidatenverteilung

$$q(\Phi^{G+1} | \Phi^G) := f(\Phi^{G+1}) \quad (\text{unabhängig von } \Phi^G!)$$

Dann berechnet man die Akzeptanzwahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$r := \frac{\pi(\Phi^{G+1})/q(\Phi^{G+1} | \Phi^G)}{\pi(\Phi^G)/q(\Phi^G | \Phi^{G+1})} = \frac{f(\Phi^{G+1}) \cdot g(\Phi^{G+1})/f(\Phi^{G+1})}{f(\Phi^G) \cdot g(\Phi^G)/f(\Phi^G)} = \frac{g(\Phi^{G+1})}{g(\Phi^G)}$$

Zuletzt zieht man  $u \sim \mathcal{U}(0, 1)$  und man behält  $\Phi^{G+1}$ , falls  $u < \alpha$ . Ansonsten verwirft man  $\Phi^{G+1}$ . **TODO: Sprache mit verwerfen ein wenig anpassen.**

# Das stochastische Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), & t = 1, \dots, T & \quad (\text{Beobachtungsgl.}) \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), & t = 1, \dots, T & \quad (\text{Zustandsgl.}) \end{aligned}$$



# Das stochastische Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), & t &= 1, \dots, T & \quad (\text{Beobachtungsgl.}) \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), & t &= 1, \dots, T & \quad (\text{Zustandsgl.}) \end{aligned}$$

## Beispiel

TODO: Aktien? Graphik?

# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned}y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T\end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$f(h_t | h_{-t}, \vec{y}, g) = f(h_t | h_{t-1}, h_{t+1}, y_t, g)$$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned}y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T\end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned}f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g)\end{aligned}$$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g) \end{aligned}$$

$$f(y_t | h_t) = \frac{1}{\sqrt{2\pi}h_t} \exp\left(\frac{-y_t^2}{2h_t}\right) \quad (\text{Normalverteilung})$$

$$f(h_{t+1} | h_t) = \frac{1}{\sqrt{2\pi}} \frac{1}{h_{t+1}} \exp\left(\frac{-(\ln h_{t+1} - \ln h_t)^2}{2g}\right) \quad (\text{Log. Normalvert.})$$

$$f(h_t | h_{t-1}) = \frac{1}{\sqrt{2\pi}} \frac{1}{h_t} \exp\left(\frac{-(\ln h_t - \ln h_{t-1})^2}{2g}\right) \quad (\text{Log. Normalvert.})$$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g) \\ &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \cdot \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu_t)^2}{2\sigma_t}\right) \\ &\quad \text{mit } \mu_t := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_t := \frac{1}{2}g \end{aligned}$$

$$\begin{aligned} f(y_t | h_t) &= \frac{1}{\sqrt{2\pi h_t}} \exp\left(\frac{-y_t^2}{2h_t}\right) && \text{(Normalverteilung)} \\ f(h_{t+1} | h_t) &= \frac{1}{\sqrt{2\pi}} \frac{1}{h_{t+1}} \exp\left(\frac{-(\ln h_{t+1} - \ln h_t)^2}{2g}\right) && \text{(Log. Normalvert.)} \\ f(h_t | h_{t-1}) &= \frac{1}{\sqrt{2\pi}} \frac{1}{h_t} \exp\left(\frac{-(\ln h_t - \ln h_{t-1})^2}{2g}\right) && \text{(Log. Normalvert.)} \end{aligned}$$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned}y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T\end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned}f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g) \\ &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \cdot \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu_t)^2}{2\sigma_t}\right) \\ &\quad \text{mit } \mu_t := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_t := \frac{1}{2}g\end{aligned}$$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g) \\ &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \cdot \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu_t)^2}{2\sigma_t^2}\right) \\ &\quad \text{mit } \mu_t := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_t^2 := \frac{1}{2}g \end{aligned}$$

Wir erfinden eine weitere Volatilitätsvariable  $h_0$  hinzu. Diese habe die Prior-Verteilung  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$ .

# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g) \\ &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \cdot \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu_t)^2}{2\sigma_t^2}\right) \\ &\quad \text{mit } \mu_t := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_t^2 := \frac{1}{2}g \end{aligned}$$

Wir erfinden eine weitere Volatilitätsvariable  $h_0$  hinzu. Diese habe die Prior-Verteilung  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$ . Für den Posterior gilt:

$$\begin{aligned} f(h_0 | h_1, g) &\propto f(h_0) \cdot f(h_1 | h_0, g) \\ &\propto \frac{1}{\sqrt{\bar{\sigma}^2}} \exp\left(-\frac{(h_0 - \bar{\mu})^2}{2\bar{\sigma}^2}\right) \cdot \frac{1}{h_0} \exp\left(-\frac{(\ln h_1 - \ln h_0)^2}{2g}\right) \end{aligned}$$



# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &= f(h_t | h_{t-1}, h_{t+1}, y_t, g) \\ &\propto f(y_t | h_t, g) \cdot f(h_{t+1} | h_t, g) \cdot f(h_t | h_{t-1}, g) \\ &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \cdot \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu_t)^2}{2\sigma_t^2}\right) \\ &\quad \text{mit } \mu_t := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_t := \frac{1}{2}g \end{aligned}$$

Wir erfinden eine weitere Volatilitätsvariable  $h_0$  hinzu. Diese habe die Prior-Verteilung  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$ . Für den Posterior gilt:

$$\begin{aligned} f(h_0 | h_1, g) &\propto f(h_0) \cdot f(h_1 | h_0, g) \\ &\propto \frac{1}{\sqrt{\bar{\sigma}^2}} \exp\left(-\frac{(h_0 - \bar{\mu})^2}{2\bar{\sigma}^2}\right) \cdot \frac{1}{h_0} \exp\left(-\frac{(\ln h_1 - \ln h_0)^2}{2g}\right) \\ &\propto \frac{1}{h_0} \exp\left(-\frac{(\ln h_0 - \mu_0)^2}{2\sigma_0^2}\right) \\ &\quad \text{mit } \sigma_0 := \frac{\bar{\sigma}g}{\bar{\sigma}+g}, \quad \mu_0 := \sigma_0 \left( \frac{\bar{\mu}}{\bar{\sigma}} + \frac{\ln h_1}{g} \right) \end{aligned}$$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \cdot \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu_t)^2}{2\sigma_t}\right) \\ &\text{mit } \mu_t := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_t := \frac{1}{2}g \end{aligned}$$

Wir erfinden eine weitere Volatilitätsvariable  $h_0$  hinzu. Diese habe die Prior-Verteilung  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$ . Für den Posterior gilt:

$$\begin{aligned} f(h_0 | h_1, g) &\propto \frac{1}{h_0} \exp\left(\frac{-(\ln h_0 - \mu_0)^2}{2\sigma_0}\right) \\ &\text{mit } \sigma_0 := \frac{\bar{\sigma}g}{\bar{\sigma}+g}, \quad \mu_0 := \sigma_0 \left(\frac{\bar{\mu}}{\bar{\sigma}} + \frac{\ln h_1}{g}\right) \end{aligned}$$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \cdot \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu_t)^2}{2\sigma_t}\right) \\ &\text{mit } \mu_t := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_t := \frac{1}{2}g \end{aligned}$$

Wir erfinden eine weitere Volatilitätsvariable  $h_0$  hinzu. Diese habe die Prior-Verteilung  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$ . Für den Posterior gilt:

$$\begin{aligned} f(h_0 | h_1, g) &= \frac{1}{\sqrt{2\pi}} \frac{1}{h_0} \exp\left(\frac{-(\ln h_0 - \mu_0)^2}{2\sigma_0}\right) \\ &\text{mit } \sigma_0 := \frac{\bar{\sigma}g}{\bar{\sigma}+g}, \quad \mu_0 := \sigma_0 \left(\frac{\bar{\mu}}{\bar{\sigma}} + \frac{\ln h_1}{g}\right) \end{aligned}$$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \cdot \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu_t)^2}{2\sigma_t}\right) \\ &\text{mit } \mu_t := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_t := \frac{1}{2}g \end{aligned}$$

Wir erfinden eine weitere Volatilitätsvariable  $h_0$  hinzu. Diese habe die Prior-Verteilung  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$ . Für den Posterior gilt:

$$\begin{aligned} f(h_0 | h_1, g) &= \frac{1}{\sqrt{2\pi}} \frac{1}{h_0} \exp\left(\frac{-(\ln h_0 - \mu_0)^2}{2\sigma_0}\right) \\ &\text{mit } \sigma_0 := \frac{\bar{\sigma}g}{\bar{\sigma}+g}, \quad \mu_0 := \sigma_0 \left(\frac{\bar{\mu}}{\bar{\sigma}} + \frac{\ln h_1}{g}\right) \end{aligned}$$

Für die letzte Volatilitätsvariable  $h_T$  gilt

$$f(h_T | h_{-T}, \vec{y}, g) = f(h_T, h_{T-1}, y_T, g)$$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \cdot \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu_t)^2}{2\sigma_t}\right) \\ &\text{mit } \mu_t := \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_t := \frac{1}{2}g \end{aligned}$$

Wir erfinden eine weitere Volatilitätsvariable  $h_0$  hinzu. Diese habe die Prior-Verteilung  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$ . Für den Posterior gilt:

$$\begin{aligned} f(h_0 | h_1, g) &= \frac{1}{\sqrt{2\pi}} \frac{1}{h_0} \exp\left(-\frac{(\ln h_0 - \mu_0)^2}{2\sigma_0}\right) \\ &\text{mit } \sigma_0 := \frac{\bar{\sigma}g}{\bar{\sigma}+g}, \quad \mu_0 := \sigma_0 \left(\frac{\bar{\mu}}{\bar{\sigma}} + \frac{\ln h_1}{g}\right) \end{aligned}$$

Für die letzte Volatilitätsvariable  $h_T$  gilt

$$\begin{aligned} f(h_T | h_{-T}, \vec{y}, g) &= f(h_T, h_{T-1}, y_T, g) \\ &\propto f(y_T | h_T) \cdot f(h_T | h_{T-1}) \end{aligned}$$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \cdot \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu_t)^2}{2\sigma_t}\right) \\ \text{mit } \mu_t &:= \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_t := \frac{1}{2}g \end{aligned}$$

Wir erfinden eine weitere Volatilitätsvariable  $h_0$  hinzu. Diese habe die Prior-Verteilung  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$ . Für den Posterior gilt:

$$\begin{aligned} f(h_0 | h_1, g) &= \frac{1}{\sqrt{2\pi}} \frac{1}{h_0} \exp\left(\frac{-(\ln h_0 - \mu_0)^2}{2\sigma_0}\right) \\ \text{mit } \sigma_0 &:= \frac{\bar{\sigma}g}{\bar{\sigma}+g}, \quad \mu_0 := \sigma_0 \left(\frac{\bar{\mu}}{\bar{\sigma}} + \frac{\ln h_1}{g}\right) \end{aligned}$$

Für die letzte Volatilitätsvariable  $h_T$  gilt

$$\begin{aligned} f(h_T | h_{-T}, \vec{y}, g) &= f(h_T, h_{T-1}, y_T, g) \\ &\propto f(y_T | h_T) \cdot f(h_T | h_{T-1}) \\ &\propto \frac{1}{\sqrt{h_T}} \exp\left(-\frac{y_T^2}{2h_T}\right) \cdot \frac{1}{h_T} \exp\left(-\frac{(\ln h_T - \mu_T)^2}{2\sigma_T}\right) \\ \text{mit } \mu_T &:= \ln h_{T-1}, \quad \sigma_T := g \end{aligned}$$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

$$\begin{aligned} y_t &= \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), \quad t = 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), \quad t = 1, \dots, T \end{aligned}$$

Vorüberlegung: Für alle Zeitpunkte  $t$ , außer Start- und Endzeitpunkt, gilt:

$$\begin{aligned} f(h_t | h_{-t}, \vec{y}, g) &\propto \frac{1}{\sqrt{h_t}} \exp\left(-\frac{y_t^2}{2h_t}\right) \cdot \frac{1}{h_t} \exp\left(-\frac{(\ln h_t - \mu_t)^2}{2\sigma_t}\right) \\ \text{mit } \mu_t &:= \frac{1}{2}(\ln h_{t+1} + \ln h_{t-1}), \quad \sigma_t := \frac{1}{2}g \end{aligned}$$

Wir erfinden eine weitere Volatilitätsvariable  $h_0$  hinzu. Diese habe die Prior-Verteilung  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$ . Für den Posterior gilt:

$$\begin{aligned} f(h_0 | h_1, g) &= \frac{1}{\sqrt{2\pi}} \frac{1}{h_0} \exp\left(\frac{-(\ln h_0 - \mu_0)^2}{2\sigma_0}\right) \\ \text{mit } \sigma_0 &:= \frac{\bar{\sigma}g}{\bar{\sigma}+g}, \quad \mu_0 := \sigma_0 \left(\frac{\bar{\mu}}{\bar{\sigma}} + \frac{\ln h_1}{g}\right) \end{aligned}$$

Für die letzte Volatilitätsvariable  $h_T$  gilt

$$\begin{aligned} f(h_T | h_{-T}, \vec{y}, g) &\propto \frac{1}{\sqrt{h_T}} \exp\left(-\frac{y_T^2}{2h_T}\right) \cdot \frac{1}{h_T} \exp\left(\frac{-(\ln h_T - \mu_T)^2}{2\sigma_T}\right) \\ \text{mit } \mu_T &:= \ln h_{T-1}, \quad \sigma_T := g \end{aligned}$$

# Bayessche Inferenz im stochastischen Volatilitätsmodell



# Bayessche Inferenz im stochastischen Volatilitätsmodell

A. Setze die Parameter der Prior-Vert.  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$  sowie  $g \sim \mathcal{IG}(\frac{g_0}{2}, \frac{\nu_0}{2})$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

- A. Setze die Parameter der Prior-Vert.  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$  sowie  $g \sim \mathcal{IG}(\frac{g_0}{2}, \frac{\nu_0}{2})$
- B. Initialisierung: Wähle Startwerte für  $h_0, \dots, h_T$  und  $g$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

- A. Setze die Parameter der Prior-Vert.  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$  sowie  $g \sim \mathcal{IG}(\frac{g_0}{2}, \frac{\nu_0}{2})$
- B. Initialisierung: Wähle Startwerte für  $h_0, \dots, h_T$  und  $g$
- C. Gibbs-Sampling: Wiederhole die Schritte

# Bayessche Inferenz im stochastischen Volatilitätsmodell

- A. Setze die Parameter der Prior-Vert.  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$  sowie  $g \sim \mathcal{IG}(\frac{g_0}{2}, \frac{\nu_0}{2})$
- B. Initialisierung: Wähle Startwerte für  $h_0, \dots, h_T$  und  $g$
- C. Gibbs-Sampling: Wiederhole die Schritte
  1. Führe einen Metropolis-Hastings-Schritt für  $h_0, \dots, h_T$  aus:

# Bayessche Inferenz im stochastischen Volatilitätsmodell

- A. Setze die Parameter der Prior-Vert.  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$  sowie  $g \sim \mathcal{IG}(\frac{g_0}{2}, \frac{\nu_0}{2})$
- B. Initialisierung: Wähle Startwerte für  $h_0, \dots, h_T$  und  $g$
- C. Gibbs-Sampling: Wiederhole die Schritte
1. Führe einen Metropolis-Hastings-Schritt für  $h_0, \dots, h_T$  aus:
    - Ziehe  $h_0$  neu aus aus der logarithmischen Normalverteilung

$$f(h_0 | h_1, g) = \frac{1}{\sqrt{2\pi}} \frac{1}{h_0} \exp\left(\frac{-(\ln h_0 - \mu_0)^2}{2\sigma_0}\right), \quad \sigma_0 := \frac{\bar{\sigma}g}{\bar{\sigma}+g}, \quad \mu_0 := \sigma_0 \left(\frac{\bar{\mu}}{\bar{\sigma}} + \frac{\ln h_1}{g}\right)$$

# Bayessche Inferenz im stochastischen Volatilitätsmodell

A. Setze die Parameter der Prior-Vert.  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$  sowie  $g \sim \mathcal{IG}(\frac{g_0}{2}, \frac{\nu_0}{2})$

B. Initialisierung: Wähle Startwerte für  $h_0, \dots, h_T$  und  $g$

C. Gibbs-Sampling: Wiederhole die Schritte

1. Führe einen Metropolis-Hastings-Schritt für  $h_0, \dots, h_T$  aus:

- Ziehe  $h_0$  neu aus der logarithmischen Normalverteilung

$$f(h_0 | h_1, g) = \frac{1}{\sqrt{2\pi}} \frac{1}{h_0} \exp\left(\frac{-(\ln h_0 - \mu_0)^2}{2\sigma_0}\right), \quad \sigma_0 := \frac{\bar{\sigma}g}{\bar{\sigma}+g}, \quad \mu_0 := \sigma_0 \left(\frac{\bar{\mu}}{\bar{\sigma}} + \frac{\ln h_1}{g}\right)$$

- Für  $t = 1, \dots, T$  ziehe einen Kandidaten  $h_{t,\text{new}}$  gemäß der log. NV

$$q(h_{t,\text{new}}) = \frac{1}{h_{t,\text{new}}} \exp\left(\frac{-(\ln h_{t,\text{new}} - \mu_t)^2}{2\sigma_t}\right)$$

mit  $\mu_t$  und  $\sigma_t$  wie auf der letzten Folie.

Berechne die Akzeptanz-Wahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$r := \frac{h_{t,\text{new}}^{-0,5} \exp(-y_t^2/2h_{t,\text{new}})}{h_{t,\text{old}}^{-0,5} \exp(-y_t^2/2h_{t,\text{old}})}$$

Ziehe  $u \sim \mathcal{U}(0, 1)$ . Behalte  $h_{t,\text{new}}$ , falls  $u < \alpha$ , ansonsten verwirfe  $h_{t,\text{new}}$ .

# Bayessche Inferenz im stochastischen Volatilitätsmodell

A. Setze die Parameter der Prior-Vert.  $h_0 \sim \mathcal{N}(\bar{\mu}, \bar{\sigma}^2)$  sowie  $g \sim \mathcal{IG}(\frac{g_0}{2}, \frac{\nu_0}{2})$

B. Initialisierung: Wähle Startwerte für  $h_0, \dots, h_T$  und  $g$

C. Gibbs-Sampling: Wiederhole die Schritte

1. Führe einen Metropolis-Hastings-Schritt für  $h_0, \dots, h_T$  aus:

- Ziehe  $h_0$  neu aus der logarithmischen Normalverteilung

$$f(h_0 | h_1, g) = \frac{1}{\sqrt{2\pi}} \frac{1}{h_0} \exp\left(\frac{-(\ln h_0 - \mu_0)^2}{2\sigma_0}\right), \quad \sigma_0 := \frac{\bar{\sigma}g}{\bar{\sigma} + g}, \quad \mu_0 := \sigma_0 \left(\frac{\bar{\mu}}{\bar{\sigma}} + \frac{\ln h_1}{g}\right)$$

- Für  $t = 1, \dots, T$  ziehe einen Kandidaten  $h_{t,\text{new}}$  gemäß der log. NV

$$q(h_{t,\text{new}}) = \frac{1}{h_{t,\text{new}}} \exp\left(\frac{-(\ln h_{t,\text{new}} - \mu_t)^2}{2\sigma_t}\right)$$

mit  $\mu_t$  und  $\sigma_t$  wie auf der letzten Folie.

Berechne die Akzeptanz-Wahrscheinlichkeit  $\alpha = \min(1, r)$  mit

$$r := \frac{h_{t,\text{new}}^{-0,5} \exp(-y_t^2/2h_{t,\text{new}})}{h_{t,\text{old}}^{-0,5} \exp(-y_t^2/2h_{t,\text{old}})}$$

Ziehe  $u \sim \mathcal{U}(0, 1)$ . Behalte  $h_{t,\text{new}}$ , falls  $u < \alpha$ , ansonsten verwirfe  $h_{t,\text{new}}$ .

2. Sample  $g$  gegeben  $h_0, \dots, h_T$ : Ziehe ein neues  $g$  aus der Posterior-Verteilung  $\mathcal{IG}(\frac{g}{2}, \frac{\nu}{2})$  mit  $g := g_0 + \sum_{t=1}^T \nu_t = g_0 + \sum_{t=1}^T \ln h_t - \ln h_{t-1}$  und  $\nu := \nu_0 + T$ .

# Erweiterte Version des stochastischen Volatilitätsmodells

$$\begin{aligned} y_t &= c_t + b_t y_{t-1} + \epsilon_t \sqrt{h_t}, & \epsilon_t &\sim \mathcal{N}(0, 1), & t &= 1, \dots, T \\ \ln h_t &= \ln h_{t-1} + v_t, & v_t &\sim \mathcal{N}(0, g), & t &= 1, \dots, T \end{aligned}$$

Für die Regressions-Koeffizienten  $B_t = \{c_t, b_t\}$  gelte dabei

$$B_t = B_{t-1} + e_t, \quad e_t \sim \mathcal{N}(0, Q), \quad Q \in \mathbb{R}^{2 \times 2}.$$

TODO: Motivation



# Bayessche Inferenz im erw. stoch. Volatilitätsmodell

A. Initialisierung: Wähle Startwerte für **TODO: ???**

B. Gibbs-Sampling: Wiederhole die Schritte

1. Sample  $h_0, \dots, h_T$  gegeben  $g$  und  $B_1, \dots, B_T$ : Für  $t = 1, \dots, T - 1$  führe einen MH-Schritt für  $h_t$  aus